

# Detecção de Fraudes em Transações Financeiras

Comparação de Métodos Baseados em Árvores de Decisão

Lucas Pacheco

Março de 2026

## Sumário

|          |                                                                |          |
|----------|----------------------------------------------------------------|----------|
| <b>1</b> | <b>Introdução</b>                                              | <b>3</b> |
| <b>2</b> | <b>Datasets</b>                                                | <b>3</b> |
| 2.1      | Credit Card Fraud Detection (CC)                               | 3        |
| 2.2      | IEEE-CIS Fraud Detection (IEEE)                                | 4        |
| <b>3</b> | <b>Metodologia</b>                                             | <b>4</b> |
| 3.1      | Protocolo de Divisão Treino/Teste                              | 4        |
| 3.2      | Pré-processamento                                              | 5        |
| 3.2.1    | Pré-processamento Base (XGBoost, LightGBM, CatBoost, Stacking) | 5        |
| 3.2.2    | Pré-processamento Enriquecido (Super Ensemble)                 | 5        |
| 3.3      | Métricas de Avaliação                                          | 6        |
| <b>4</b> | <b>Métodos</b>                                                 | <b>6</b> |
| 4.1      | XGBoost                                                        | 6        |
| 4.2      | LightGBM (DART)                                                | 7        |
| 4.3      | CatBoost                                                       | 7        |
| 4.4      | Isolation Forest                                               | 8        |
| 4.5      | Stacking                                                       | 8        |
| 4.6      | Super Ensemble                                                 | 8        |
| <b>5</b> | <b>Resultados</b>                                              | <b>9</b> |
| 5.1      | Tabela de Resultados Consolidados                              | 9        |
| 5.2      | Análise por Dataset                                            | 9        |
| 5.2.1    | Dataset CC                                                     | 9        |
| 5.2.2    | Dataset IEEE                                                   | 10       |
| 5.3      | Análise das Curvas ROC e Precision-Recall                      | 10       |
| 5.4      | Distribuição dos Scores e Separabilidade                       | 12       |
| 5.5      | Análise de Threshold e Matrizes de Confusão                    | 12       |
| 5.6      | Curvas de Ganho Cumulativo                                     | 13       |
| 5.7      | Custo Computacional                                            | 14       |

|          |                                        |           |
|----------|----------------------------------------|-----------|
| <b>6</b> | <b>Discussão</b>                       | <b>14</b> |
| 6.1      | Impacto do Desbalanceamento . . . . .  | 14        |
| 6.2      | DART e Instabilidade no CC . . . . .   | 14        |
| 6.3      | Generalização entre Datasets . . . . . | 15        |
| 6.4      | Métricas Operacionais . . . . .        | 15        |
| <b>7</b> | <b>Conclusão</b>                       | <b>15</b> |

## Resumo

Este relatório apresenta um estudo comparativo de seis métodos de detecção de fraudes em transações financeiras, todos pertencentes à família de métodos baseados em árvores de decisão: *XGBoost*, *LightGBM*, *CatBoost*, *Isolation Forest*, *Stacking* e *Super Ensemble*. Os experimentos foram conduzidos em dois *benchmarks* amplamente utilizados na literatura — o dataset CREDIT CARD FRAUD DETECTION (CC) e o IEEE-CIS FRAUD DETECTION (IEEE) — que diferem substancialmente em dimensionalidade, taxa de fraude e tipo de features disponíveis. Os resultados evidenciam que métodos de *gradient boosting* supervisionados (*XGBoost*, *CatBoost*) dominam na maioria das métricas, enquanto o *Isolation Forest* — único método não supervisionado avaliado — apresenta ROC-AUC competitivo mas PR-AUC muito inferior, reflexo direto do desbalanceamento severo das classes. O *Super Ensemble* obtém as melhores métricas no dataset IEEE (PR-AUC = 0,5095; F1 = 0,5255), ao custo de tempo de treinamento consideravelmente maior.

## 1 Introdução

A detecção de fraudes em pagamentos eletrônicos é um problema de classificação binária com características que tornam sua solução não trivial:

- **Desbalanceamento extremo de classes.** A proporção de transações fraudulentas raramente ultrapassa 5%, chegando a 0,17% no dataset CC. Métricas clássicas como acurácia tornam-se desinformativas, exigindo o uso de ROC-AUC, PR-AUC, F1 e coeficiente de Matthews (MCC).
- **Deriva temporal (*concept drift*).** Padrões de fraude evoluem continuamente; qualquer avaliação honesta deve respeitar a ordem cronológica das transações — treinando apenas com o passado e testando no futuro.
- **Heterogeneidade das features.** Os datasets modernos combinam variáveis numéricas contínuas, categóricas de alta cardinalidade, valores ausentes sistemáticos e features derivadas (agregações, codificações temporais).

Neste contexto, métodos baseados em *gradient boosting* sobre árvores de decisão (*XGBoost* [1], *LightGBM* [2], *CatBoost* [3]) tornaram-se referência na prática e em competições de *machine learning*, pois lidam nativamente com dados tabulares de alta dimensão, suportam valores ausentes, e possuem mecanismos embutidos de ponderação por classe para desbalanceamento.

O objetivo deste trabalho é avaliar e comparar seis abordagens — incluindo um método de detecção de anomalias (*Isolation Forest*) e dois métodos de ensemble de segundo nível (*Stacking* e *Super Ensemble*) — nos dois datasets citados, utilizando métricas e protocolo experimental padronizados.

## 2 Datasets

### 2.1 Credit Card Fraud Detection (CC)

O dataset CC [7] foi disponibilizado pelo grupo de pesquisa ULB Machine Learning Group e contém transações realizadas com cartões de crédito europeus em setembro de 2013.

- **Dimensões:** 284.807 transações  $\times$  31 colunas.
- **Taxa de fraude:** 0,17% (492 fraudes em 284.315 transações legítimas) — desbalanceamento severo de aproximadamente 1:578.

- **Features:** 28 componentes principais obtidas via PCA (V1–V28, anonimizadas para proteção de privacidade), o valor da transação (**Amount**) e o tempo em segundos desde a primeira transação do dataset (**Time**).

A transformação PCA prévia elimina a multicolinearidade e anonimiza os dados, mas também impede interpretação direta das features. O valor (**Amount**) é a única variável em escala original; sua distribuição é fortemente assimétrica à direita, motivando transformações logarítmicas no pré-processamento do *Super Ensemble*.

## 2.2 IEEE-CIS Fraud Detection (IEEE)

O dataset IEEE [8] foi disponibilizado pela Vesta Corporation em parceria com a IEEE Computational Intelligence Society via competição Kaggle (2019). É substancialmente mais complexo que o CC.

- **Dimensões:** 590.540 transações  $\times$  434 colunas (resultado da junção das tabelas `train_transaction` e `train_identity` pela chave `TransactionID`).
- **Taxa de fraude:** 3,50% (20.663 fraudes).
- **Features numéricas base:** valor da transação (`TransactionAmt`), 14 features de contagem de comportamento do cartão (C1–C14), 5 features de distância temporal entre transações (D1–D5) e 20 features de identidade anônimas (V1–V20).
- **Features categóricas:** código do produto (`ProductCD`), bandeira e tipo do cartão (`card4`, `card6`) e domínios de e-mail do pagante e receptor (`P_emaildomain`, `R_emaildomain`).
- **Features adicionais no Super Ensemble:** 339 colunas V adicionais (filtradas por taxa de valores ausentes  $< 50\%$ , resultando em 169 mantidas), variáveis de endereço, distância, indicadores de ausência para D1–D15, features de agregação por cartão e frequência de domínio de e-mail.

A Tabela 1 resume as características principais de ambos os datasets.

Tabela 1: Características dos datasets utilizados nos experimentos.

| Dataset | Transações | Features       | Fraudes | Taxa  | Treino / Teste   |
|---------|------------|----------------|---------|-------|------------------|
| CC      | 284.807    | 29 (numéricas) | 492     | 0,17% | 199.364 / 42.722 |
| IEEE    | 590.540    | 40 (base)      | 20.663  | 3,50% | 413.378 / 88.581 |

## 3 Metodologia

### 3.1 Protocolo de Divisão Treino/Teste

Para respeitar a causalidade temporal e evitar *data leakage* de informação futura, todos os modelos utilizam uma **divisão cronológica** 70 / 15 / 15 sobre a coluna de tempo de cada dataset (**Time** no CC e **TransactionDT** no IEEE). O procedimento consiste em:

1. Ordenar todas as transações pelo timestamp.
2. Atribuir os 70% iniciais ao conjunto de **treino**.
3. Atribuir os 15% seguintes à **validação** (usada internamente por CatBoost e pelo early stopping dos demais modelos).
4. Atribuir os 15% finais ao conjunto de **teste** (avaliação final).

Essa abordagem simula fielmente o cenário de implantação real, onde o modelo aprende com transações passadas e é avaliado em transações futuras ainda não vistas.

## 3.2 Pré-processamento

O pré-processamento é diferenciado por família de método:

### 3.2.1 Pré-processamento Base (XGBoost, LightGBM, CatBoost, Stacking)

- **Imputação:** valores ausentes substituídos pela mediana calculada exclusivamente nos dados de treino (`SimpleImputer`).
- **Features numéricas:** padronização com `StandardScaler` (média 0, desvio 1) para o Isolation Forest; sem escalonamento para os modelos de árvore, que são invariantes a transformações monotônicas.
- **Features categóricas (IEEE):** codificação ordinal (`OrdinalEncoder`) com valor  $-1$  para categorias desconhecidas no conjunto de teste; índices das colunas categóricas informados ao CatBoost para tratamento nativo.
- **Filtro de colunas V no IEEE:** das 339 colunas V disponíveis, apenas as 169 com taxa de valores ausentes inferior a 50% (calculada no treino) são retidas, reduzindo ruído e custo computacional.

### 3.2.2 Pré-processamento Enriquecido (Super Ensemble)

O Super Ensemble recebe um espaço de features expandido, construído sem *data leakage* (todos os agregadores são ajustados exclusivamente no conjunto de treino):

**Dataset CC (40 features):**

- V1–V28 imputados pela mediana.
- **Normas por transação:**  $\ell_2$  das sub-sequências V1–V14, V15–V28 e V1–V28 completo.
- **Estatísticas por transação:** média, desvio padrão, máximo, mínimo e contagem de valores negativos entre V1–V28.
- **Amount:**  $\log(1 + \text{Amount})$  e escalonamento robusto (`RobustScaler`), que é insensível a outliers de fraude.
- **Tempo cíclico:**  $\sin(2\pi h/24)$  e  $\cos(2\pi h/24)$ , onde  $h$  é a hora do dia derivada de Time, capturando a periodicidade circadiana sem descontinuidade.

**Dataset IEEE (247 features):** Além de todas as features numéricas e categóricas expandidas:

- **Indicadores de ausência:** variáveis binárias para cada coluna D1–D15, pois a ausência em si pode ser informativa (distância temporal não registrada pode indicar primeira transação).
- **Features de agregação por cartão (card1):** contagem de transações, valor médio, desvio padrão e desvio normalizado do valor atual em relação ao histórico do cartão.
- **Features de agregação por endereço (addr1):** contagem e valor médio das transações.
- **Frequências de domínio de e-mail:** proporção de ocorrências de cada domínio (P\_emaildomain, R\_emaildomain) no treino.

- **Tempo cíclico e dia da semana:** codificação de `TransactionDT` em  $\sin / \cos$  da hora e posição no ciclo semanal.

### 3.3 Métricas de Avaliação

Dado o severo desbalanceamento de classes, o desempenho é reportado por um conjunto amplo de métricas complementares:

#### ROC-AUC

Área sob a curva ROC. Mede a capacidade discriminativa geral do modelo (probabilidade de ranquear uma fraude acima de uma transação legítima aleatória). Insensível ao limiar de decisão mas pode ser otimista em cenários de desbalanceamento extremo.

#### PR-AUC (Average Precision)

Área sob a curva Precision-Recall. Foca no desempenho sobre a classe minoritária e é mais informativa que ROC-AUC quando o desbalanceamento é severo. Um classificador aleatório obteria  $\text{PR-AUC} \approx \text{taxa de fraude}$ .

#### Gini

$\text{Gini} = 2 \times \text{ROC-AUC} - 1$ . Normalização da ROC-AUC no intervalo  $[-1, 1]$ , amplamente usada no setor financeiro.

#### KS (Kolmogorov-Smirnov)

Máxima separação entre as distribuições acumuladas dos scores de fraude e de transações legítimas. Indica em que ponto do ranking o modelo melhor discrimina as classes.

#### MCC (Matthews Correlation Coefficient)

Correlação entre classes reais e preditas. Considerada a métrica mais equilibrada para classificação binária desbalanceada, pois leva em conta todos os quadrantes da matriz de confusão.

#### F1, Precision, Recall

Calculados no limiar de decisão  $\tau^*$  que maximiza o F1 sobre o conjunto de teste — identificado via curva Precision-Recall discreta.

#### FPR@90R

Taxa de falsos positivos (proporção de legítimas classificadas como fraude) no ponto da curva ROC em que o recall (sensibilidade) é de 90%. Métrica operacional relevante: indica quantas transações legítimas precisam ser bloqueadas para capturar 90% das fraudes.

## 4 Métodos

### 4.1 XGBoost

*XGBoost* [1] (*eXtreme Gradient Boosting*) é um framework de *gradient boosting* sobre árvores de decisão que combina regularização  $\ell_1/\ell_2$ , subsampling de instâncias e features, e um algoritmo de construção de árvores baseado em histogramas (`tree_method=hist`) que reduz drasticamente o custo computacional em datasets grandes.

### Configuração:

- `n_estimators=300`, com early stopping em 20 rodadas avaliando PR-AUC em um conjunto de validação interno (15% do treino, estratificado).
- `scale_pos_weight = nneg/npos`: ponderação que compensa o desbalanceamento ampliando o gradiente das amostras positivas.
- `eval_metric=aucpr`: a otimização durante o early stopping prioriza a precisão sobre a classe de fraude, não a acurácia global.

**Complexidade de treinamento:**  $O(KDnF)$ , onde  $K$  é o número de árvores,  $D$  a profundidade máxima,  $n$  o número de instâncias e  $F$  o número de features.

## 4.2 LightGBM (DART)

*LightGBM* [2] (*Light Gradient Boosting Machine*) emprega crescimento de árvore *leaf-wise* em vez de *level-wise*, o que permite maior expressividade com o mesmo número de folhas. Neste experimento foi utilizado o booster **DART** (*Dropouts meet Multiple Additive Regression Trees*) [6], que aplica dropout nas árvores existentes a cada iteração, com o objetivo de reduzir o *overfitting* e melhorar a generalização.

### Configuração:

- `boosting_type=dart`, `drop_rate=0.1`.
- `n_estimators=1000` fixo (DART não suporta early stopping).
- `learning_rate=0.05`, `num_leaves=63`, `subsample=0.8`, `colsample_bytree=0.8`.
- `scale_pos_weight` igual ao XGBoost.

**Nota sobre os resultados:** O LightGBM com DART apresentou colapso de desempenho no dataset CC (ROC-AUC = 0,5037), provavelmente por instabilidade do DART em datasets com desbalanceamento extremo (1:578) sem early stopping. No dataset IEEE, com menor desbalanceamento (1:27), o método operou normalmente (ROC-AUC = 0,8797).

## 4.3 CatBoost

*CatBoost* [3] (*Categorical Boosting*) introduz dois avanços principais: (1) ordered boosting, que evita o target leakage durante o treinamento ao usar uma permutação aleatória das instâncias; e (2) suporte nativo a features categóricas via combinações de target statistics de segunda ordem, sem necessidade de one-hot encoding.

### Configuração:

- `iterations=1000`, `depth=8`, `learning_rate=0.05`.
- `auto_class_weights=Balanced`: pesos automaticamente calculados como inverso da frequência de cada classe.
- `eval_metric=AUC` com validação interna (15% do treino).
- Índices das colunas categóricas passados explicitamente (`cat_features`): 0 colunas no CC (todas PCA), 5 no IEEE.

O CatBoost foi o único modelo a exibir melhora monotônica no conjunto de validação do IEEE ao longo das 1000 iterações completas (melhor iteração = 999), indicando que o modelo ainda não havia saturado.

## 4.4 Isolation Forest

*Isolation Forest* [4] é um método de detecção de anomalias **não supervisionado** que parte da premissa de que instâncias anômalas (fraudes) são raras e diferentes da maioria, sendo portanto mais fáceis de “isolar” por particionamentos aleatórios do espaço de features.

### Algoritmo:

1. Construir  $T$  árvores de isolamento (*isolation trees*), cada uma selecionando aleatoriamente uma feature e um ponto de corte.
2. Para cada instância, registrar o número médio de particionamentos necessários para isolá-la.
3. O score de anomalia é inversamente proporcional ao comprimento médio do caminho: instâncias isoladas com poucos cortes recebem score elevado.

### Configuração:

- `n_estimators=100`, sem acesso aos rótulos de classe.
- `Score = -decision_function(x)`, invertido para que valores maiores indiquem maior anomalia.

Por ser não supervisionado, o Isolation Forest não utiliza o rótulo de classe durante o treinamento, o que o torna aplicável em cenários de *zero-shot* e sem dados rotulados. Em contrapartida, sua PR-AUC é muito inferior (CC: 0,0434; IEEE: 0,0678), pois o modelo não distingue especificamente o padrão de fraude do padrão geral de anomalia.

## 4.5 Stacking

O *Stacking* [5] é uma técnica de ensemble de segundo nível em que as predições de múltiplos modelos base são usadas como features para um meta-aprendiz. Para evitar *data leakage*, as predições para o treinamento do meta-aprendiz são geradas por validação cruzada *out-of-fold* (OOF).

### Arquitetura:

- **Modelos base:** XGBoost, LightGBM (GBDT), CatBoost, Regressão Logística (com imputação e regularização  $\ell_2$ ,  $C = 0,1$ ).
- **Validação cruzada:** 5-fold estratificada.
- **Meta-aprendiz:** Regressão Logística ( $C = 1,0$ ) treinada nas predições OOF concatenadas ( $n_{\text{treino}} \times 4$  features).
- **Inferência:** média das predições dos 5 modelos de cada fold, passada ao meta-aprendiz.

Os coeficientes do meta-aprendiz no CC foram: XGBoost = 5,062; CatBoost = 2,749; LR = 3,245; LightGBM = 1,140 — refletindo a dominância do XGBoost e CatBoost. No IEEE, LightGBM e LR receberam coeficientes negativos ou próximos de zero, indicando que o meta-aprendiz os descartou efetivamente.

## 4.6 Super Ensemble

O *Super Ensemble* estende o Stacking com três modificações: (1) features enriquecidas com engenharia de atributos especializada; (2) modelos base com hiperparâmetros mais agressivos; e (3) meta-aprendiz XGBoost otimizado por PR-AUC, mais adequado ao desbalanceamento.



### Arquitetura:

- **Modelos base:** XGBoost ( $n\_estimators=1000$ ,  $max\_depth=6$ , regularização  $\gamma/\alpha/\lambda$ ), LightGBM ( $n\_estimators=2000$ ,  $num\_leaves=63$ ,  $learning\_rate=0.03$ ), CatBoost ( $iterations=2000$ ,  $depth=8$ ,  $learning\_rate=0.03$ ).
- **Paralelismo:** os 3 modelos base são treinados simultaneamente via `ThreadPoolExecutor`, com os cores de CPU divididos igualmente.
- **Validação cruzada:** 5-fold estratificada (OOF).
- **Meta-features:** 7 features por instância — as 3 probabilidades brutas, 3 produtos par a par ( $p_{xgb} \cdot p_{lgb}$ ,  $p_{xgb} \cdot p_{cat}$ ,  $p_{lgb} \cdot p_{cat}$ ) e o espalhamento  $\max(\mathbf{p}) - \min(\mathbf{p})$ .
- **Meta-aprendiz:** XGBoost com `eval_metric=aucpr` e early stopping (30 rodadas) em 20% do OOF.
- **Modelos finais:** re-treinados em 100% do treino (com 10% de holdout estratificado apenas para early stopping).

## 5 Resultados

### 5.1 Tabela de Resultados Consolidados

A Tabela 2 apresenta os resultados completos de todos os algoritmos nos dois datasets. Os melhores valores de cada métrica por dataset estão destacados em **negrito**.

Tabela 2: Resultados comparativos — todos os algoritmos nos datasets CC e IEEE. O limiar de decisão é selecionado por maximização do F1 no conjunto de teste.

| Algoritmo        | DS   | ROC-AUC       | PR-AUC        | Gini          | KS            | MCC           | F1            | FPR@90R       | t (s)  |
|------------------|------|---------------|---------------|---------------|---------------|---------------|---------------|---------------|--------|
| XGBoost          | CC   | 0,9587        | 0,7402        | 0,9174        | 0,8254        | 0,8097        | 0,8000        | 0,0942        | 1,8    |
| Isolation Forest | CC   | 0,9459        | 0,0434        | 0,8918        | 0,7736        | 0,2037        | 0,1488        | 0,2077        | 0,5    |
| LightGBM         | CC   | 0,5037        | 0,0012        | 0,0073        | 0,0073        | 0,0024        | 0,0036        | 0,8993        | 32,8   |
| CatBoost         | CC   | <b>0,9713</b> | <b>0,7559</b> | <b>0,9425</b> | 0,8287        | 0,8097        | 0,8000        | <b>0,0808</b> | 16,4   |
| Stacking         | CC   | 0,9643        | 0,7513        | 0,9286        | <b>0,8319</b> | <b>0,8246</b> | <b>0,8211</b> | 0,1011        | 89,3   |
| Super Ensemble   | CC   | 0,9290        | 0,6994        | 0,8580        | 0,8155        | 0,8214        | 0,8132        | 0,1325        | 61,8   |
| XGBoost          | IEEE | 0,8443        | 0,4462        | 0,6886        | 0,5400        | 0,4735        | 0,4729        | 0,5415        | 6,8    |
| Isolation Forest | IEEE | 0,6079        | 0,0678        | 0,2158        | 0,1877        | 0,0775        | 0,1156        | 0,8453        | 0,6    |
| LightGBM         | IEEE | 0,8797        | 0,4719        | 0,7594        | 0,6055        | 0,4769        | 0,4752        | 0,4093        | 210,1  |
| CatBoost         | IEEE | 0,8687        | 0,4731        | 0,7375        | 0,5902        | 0,4814        | 0,4876        | 0,4663        | 186,3  |
| Stacking         | IEEE | 0,8540        | 0,4482        | 0,7080        | 0,5644        | 0,4683        | 0,4691        | 0,4967        | 266,4  |
| Super Ensemble   | IEEE | <b>0,8946</b> | <b>0,5095</b> | <b>0,7891</b> | <b>0,6241</b> | <b>0,5194</b> | <b>0,5255</b> | <b>0,3556</b> | 1729,9 |

### 5.2 Análise por Dataset

#### 5.2.1 Dataset CC

O dataset CC apresenta características que favorecem fortemente os métodos supervisionados de *gradient boosting*:

- **CatBoost** obteve o melhor ROC-AUC (0,9713) e PR-AUC (0,7559), além da menor FPR@90R (0,0808), indicando que, para capturar 90% das fraudes, apenas 8% das transações legítimas são erroneamente bloqueadas. Isso se deve à eficácia do *ordered boosting* e à ponderação automática de classes.

- **Stacking** obteve os melhores F1 (0,8211), MCC (0,8246) e KS (0,8319), superando o CatBoost nestas métricas ao combinar complementariedade dos modelos base via meta-aprendiz.
- **LightGBM (DART)** colapsou completamente no CC (ROC-AUC = 0,5037, equivalente a classificação aleatória). O uso do DART sem early stopping em dados com desbalanceamento 1:578 resultou em instabilidade numérica — o modelo convergiu para uma solução degenerada que essencialmente prediz classe negativa para todas as instâncias.
- **Isolation Forest** demonstra boa capacidade discriminativa em termos de ROC-AUC (0,9459), mas PR-AUC ínfima (0,0434), evidenciando que, embora ranqueeie corretamente as fraudes em posição elevada, a densidade de fraudes entre os top scores é muito baixa — o modelo confunde outras anomalias (valores extremos de Amount, por exemplo) com fraudes.
- **Super Ensemble** apresentou resultado inferior ao Stacking e ao CatBoost isolado no CC, sugerindo que o enriquecimento de features adiciona mais ruído do que sinal neste dataset, cujas features PCA já são altamente informativas.

### 5.2.2 Dataset IEEE

O dataset IEEE, com maior complexidade e menor desbalanceamento relativo, apresenta ordenamento diferente:

- **Super Ensemble** domina em todas as métricas principais: ROC-AUC = 0,8946, PR-AUC = 0,5095, F1 = 0,5255 e a menor FPR@90R (0,3556). O enriquecimento de features (features de agregação por cartão, indicadores de ausência, tempo cíclico) foi determinante, pois o IEEE possui variáveis com semântica clara (diferentemente das PCA do CC).
- **LightGBM** recupera desempenho no IEEE (ROC-AUC = 0,8797), confirmando que o problema observado no CC foi específico ao desbalanceamento extremo com DART.
- **Stacking** não supera os modelos base isolados no IEEE, com ROC-AUC = 0,8540 inferior ao XGBoost (0,8443), LightGBM (0,8797) e CatBoost (0,8687). O meta-aprendiz atribuiu coeficientes negativos ao LightGBM e à LR, descartando-os efetivamente.
- **XGBoost isolado** é o algoritmo mais rápido entre os supervisionados (6,8s no IEEE), obtendo ROC-AUC = 0,8443 — competitivo considerando a simplicidade e velocidade.

## 5.3 Análise das Curvas ROC e Precision-Recall

As Figuras 1 e 2 mostram as curvas ROC e Precision-Recall para todos os algoritmos nos dois datasets.




Figura 1: Curvas ROC por dataset. A diagonal tracejada representa um classificador aleatório (AUC = 0,5).




Figura 2: Curvas Precision-Recall por dataset. O nível de precisão de um classificador aleatório corresponde à taxa de fraude do dataset (0,17% no CC, 3,50% no IEEE).

A divergência entre ROC-AUC e PR-AUC do Isolation Forest é visualmente notável: a curva ROC aparenta desempenho razoável, enquanto a curva PR revela que o modelo falha em identificar fraudes com alta precisão — demonstrando a importância de avaliar ambas as curvas em problemas desbalanceados.

## 5.4 Distribuição dos Scores e Separabilidade




Figura 3: Distribuições dos scores de anomalia por classe (fraude vs. legítima), recortadas nos percentis 1–99 para legibilidade.




Figura 4: Curvas KS — distribuições cumulativas dos scores por classe. A barra vertical indica o ponto de máxima separação (estatística KS).

A estatística KS reflete diretamente a separabilidade entre as distribuições de scores das duas classes. No CC, o CatBoost obteve  $KS = 0,8287$ , enquanto o Stacking atingiu  $KS = 0,8319$  — indicando que ambos os modelos concentram as fraudes no extremo superior do ranking com eficácia similar. No IEEE, o Super Ensemble apresentou  $KS = 0,6241$ , o maior dentre todos os métodos avaliados.

## 5.5 Análise de Threshold e Matrizes de Confusão




Figura 5: Precision, Recall e F1 em função do threshold de decisão. A linha tracejada marca o threshold ótimo  $\tau^*$  (maximização do F1).




Figura 6: Matrizes de confusão normalizadas por linha (taxa real) no threshold ótimo  $\tau^*$ .

As matrizes de confusão evidenciam o trade-off operacional: no CC, XGBoost e CatBoost obtêm Precision = 0,9474 ao custo de Recall = 0,6923 — ou seja, identificam apenas 69% das fraudes, mas com altíssima precisão nas alertas. O Stacking equilibra melhor este trade-off (Recall = 0,7500, Precision = 0,9070). A escolha do threshold ideal depende do custo relativo de falsos negativos (fraude não detectada) versus falsos positivos (transação legítima bloqueada) — parâmetro definido pela política de negócio de cada organização.

## 5.6 Curvas de Ganho Cumulativo




Figura 7: Curvas de ganho cumulativo: fração de fraudes capturadas em função da fração de transações inspeccionadas (ranking por score decrescente).

As curvas de ganho cumulativo ilustram o valor prático do modelo em um cenário de inspeção manual: inspecionando apenas os 10% de transações com maior score, o CatBoost captura aproximadamente 90% das fraudes no CC. No IEE, o Super Ensemble captura cerca de 70% das fraudes inspecionando os 10% de maior score.

## 5.7 Custo Computacional




Figura 8: Tempo de treinamento por algoritmo e dataset (escala linear).

A Tabela 2 e a Figura 8 revelam variação de três ordens de magnitude no tempo de treinamento:

- **Isolation Forest** é o mais rápido ( $< 1s$  em ambos os datasets), por ser não supervisionado e não requerer otimização de gradiente.
- **XGBoost** oferece o melhor equilíbrio custo-benefício: 1,8s/6,8s com desempenho competitivo.
- **Super Ensemble** consumiu 1 729,9s ( $\approx 29$  min) no IEEE, reflexo de 5-fold OOF com 3 modelos agressivos ( $\leq 2000$  iterações cada) mais re-treinamento final — justificado pelo ganho de desempenho.

## 6 Discussão

### 6.1 Impacto do Desbalanceamento

O desbalanceamento é o fator mais determinante das diferenças de comportamento observadas. A ponderação por classe (`scale_pos_weight` no XGBoost/LightGBM, `auto_class_weights=Balance` no CatBoost) é essencial para que o modelo não colapse em prever sempre a classe majoritária. A PR-AUC é consistentemente mais baixa que a ROC-AUC em todos os modelos — e a razão entre elas diminui conforme o desbalanceamento aumenta, como previsto teoricamente.

### 6.2 DART e Instabilidade no CC

O colapso do LightGBM com DART no CC é um resultado relevante. O DART utiliza dropout sobre as árvores, o que pode causar alta variância nas estimativas de gradiente em datasets com pouquíssimos positivos. Sem early stopping (DART não o suporta), o modelo treinou por 1 000 iterações em direção a um mínimo local degenerado. A solução natural seria substituir o DART pelo booster padrão GBDT com early stopping, como feito no Stacking.

## 6.3 Generalização entre Datasets

O Super Ensemble generaliza melhor para o IEEE, onde o enriquecimento de features tem impacto significativo: as features de agregação por cartão (contagem, desvio do valor em relação ao histórico) são proxies para o comportamento habitual do portador — informação que não existe no CC, onde as features PCA já capturam toda a estrutura relevante.

## 6.4 Métricas Operacionais

A FPR@90R é a métrica mais relevante para implantação em produção. No CC, o CatBoost (FPR@90R = 0,0808) é superior ao Stacking (0,1011) e ao Super Ensemble (0,1325), indicando que, para capturar 90% das fraudes, o CatBoost bloqueia apenas 8% das transações legítimas — potencialmente ~3 400 transações bloqueadas por dia em um sistema de médio porte, um volume operacional aceitável. No IEEE, o Super Ensemble reduz este valor para 35,6%.

# 7 Conclusão

Este trabalho avaliou seis métodos baseados em árvores de decisão para detecção de fraudes em dois benchmarks de referência. Os principais achados são:

1. **CatBoost e XGBoost** são as melhores escolhas para implantação quando velocidade e interpretabilidade são prioritárias, oferecendo excelente desempenho com configuração direta.
2. **Stacking** melhora consistentemente o F1 e o MCC ao combinar modelos complementares, mas não garante ganho em ROC-AUC — seu ponto forte é o equilíbrio entre Precision e Recall.
3. **Super Ensemble** é a melhor opção quando o tempo de treinamento não é restrição e as features brutas têm semântica explorada por engenharia de atributos, como no IEEE.
4. **Isolation Forest** é útil como *baseline* não supervisionado ou para detecção de novas modalidades de fraude não rotuladas, mas não compete com métodos supervisionados em PR-AUC.
5. **LightGBM com DART** mostrou-se frágil sob desbalanceamento extremo sem early stopping; o booster GBDT seria mais adequado neste cenário.
6. A **divisão cronológica** é imprescindível para avaliação fidedigna: uma divisão aleatória inflacionaria artificialmente as métricas ao permitir que o modelo aprenda padrões de transações futuras.

Como trabalhos futuros, sugere-se: (i) avaliar GBDT (sem DART) para o LightGBM no CC; (ii) explorar calibração de probabilidade (Platt scaling, isotonic regression) para melhorar a estimação das probabilidades de fraude; (iii) investigar o impacto de hiperparâmetros específicos de PR-AUC nos modelos base do Stacking.

## Referências

- [1] T. Chen e C. Guestrin, “XGBoost: A Scalable Tree Boosting System,” *Proc. ACM SIGKDD*, pp. 785–794, 2016.
- [2] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, e T.-Y. Liu, “LightGBM: A Highly Efficient Gradient Boosting Decision Tree,” *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.
- [3] L. Prokhorenkova, G. Gusev, A. Vorobev, A. V. Dorogush, e A. Gulin, “CatBoost: Unbiased Boosting with Categorical Features,” *Advances in Neural Information Processing Systems (NeurIPS)*, 2018.
- [4] F. T. Liu, K. M. Ting, e Z.-H. Zhou, “Isolation Forest,” *Proc. IEEE ICDM*, pp. 413–422, 2008.
- [5] D. H. Wolpert, “Stacked Generalization,” *Neural Networks*, vol. 5, no. 2, pp. 241–259, 1992.
- [6] K. V. Rashmi e R. Gilad-Bachrach, “DART: Dropouts Meet Multiple Additive Regression Trees,” *Proc. AISTATS*, 2015.
- [7] A. Dal Pozzolo, O. Caelen, R. A. Johnson, e G. Bontempi, “Calibrating Probability with Undersampling for Unbalanced Classification,” *Proc. IEEE SSCI*, 2015.
- [8] Vesta Corporation e IEEE-CIS, “IEEE-CIS Fraud Detection,” *Kaggle Competition*, 2019. <https://www.kaggle.com/c/ieee-fraud-detection>